

Lab 6 - Fulltext

Skripty su v 6/sql/ , vystupy su v 6/outputs/ .

Skripty

- 00_inspect.sql - zakladna kontrola tabulky contracts
- 01_setup.sql - fulltext konfiguracia, tsvector stlpec a indexy
- 02_search_oracle_socialna.sql - fulltext vyhľadavanie s boostom novsich zmluv
- 03_search_accent_case.sql - kontrola case/accent insensitive vyhľadavania
- 04_search_identifier.sql - substring hľadanie v contract code cez trigram index
- 05_search_supplier_ico.sql - substring hľadanie v ICO cez trigram index
- 06_limitations.sql - jednoduché príklady limitácii

00 - Inspect

Tabulka contracts ma 475066 riadkov.

Použite stlpce:

- name
- department
- customer
- supplier
- supplier_ico
- identifier
- published_on

Stlpec identifier je contract code zo zadania.

01 - Setup

Skript 01_setup.sql vytvoril:

- extension unaccent
- extension pg_trgm

- text search konfiguráciu sk
- stlpec search_vector
- GIN index nad search_vector
- trigram index nad supplier_ico::text
- trigram index nad identifier::text

Do search_vector sa ukladaju tieto textove polia:

- name
- department
- customer
- supplier

Vystup:

Hodnota	Pocet
zmluvy so search_vector	475066

02 - Fulltext hľadanie a boost novsich zmluv

Skript: sql/02_search_oracle_socialna.sql

Vystup: outputs/02_search_oracle_socialna.txt

Dotaz hladal:

```
oracle socialna poistovna
```

Nasli sa 2 vysledky. Prvy vysledok:

id	name	supplier	published_on	text_rank	boosted_rank
101340	Zmluva o poskytovaní štandardných služieb Oracle "Software Update License & Support"	Oracle Slovensko, spol. s r.o.	2011-05-02	0.070000	0.070013

Boost je vypočítaný ako fulltext rank nasobený malou hodnotou podľa staroby zmluvy. Novšie zmluvy teda dostanú mierne vyšší rank, ale stále rozhoduje hlavne fulltext zhoda.

03 - Case/accent insensitive hľadanie

Skript: sql/03_search_accent_case.sql

Vystup: outputs/03_search_accent_case.txt

Dotaz hľadal bez diakritiky:

```
socialna poistovna
```

Vo výsledkoch sú zmluvy s textom Sociálna poisťovňa, čiže vyhľadávanie je case insensitive aj accent insensitive.

04 - Contract code

Skript: sql/04_search_identifier.sql

Vystup: outputs/04_search_identifier.txt

Dotaz:

```
identifier::text ILIKE '%OIaMIS%'
```

Výsledok:

Hodnota	Pocet
najdene zmluvy	3

Plan použil trigram index:

```
Bitmap Index Scan on contracts_identifier_trgm_idx
```

Execution time bol 10.523 ms.

05 - Supplier ICO

Skript: sql/05_search_supplier_ico.sql

Vystup: outputs/05_search_supplier_ico.txt

Dotaz:

```
supplier_ico::text ILIKE '%31364381%'
```

Vysledok:

Hodnota	Pocet vo vystupe
najdene zmluvy	10

Plan pouzil trigram index:

```
Bitmap Index Scan on contracts_supplier_ico_trgm_idx
```

Execution time bol 17.685 ms.

06 - Limitacie

Skript: sql/06_limitations.sql

Vystup: outputs/06_limitations.txt

Priklad 1:

Query	Pocet vysledkov
zmluva	265102

Slovo `zmluva` je v tychto datach prilis vseobecne. Fulltext ho sice najde, ale vysledkov je velmi vela a samotne slovo nema velku informacnu hodnotu. Riesenim by bolo pridat vlastny stopwords slovník alebo znizit vahu castych slov.

Priklad 2:

Query	Pocet vysledkov
0IaMIS cez fulltext	0

Contract code sa nesprava ako bezny prirodzeny text. Preto ho neriesim cez fulltext, ale cez `ILIKE '%...%'` s trigram indexom.

Zaver

Fulltext cast vyhladava v `name` , `department` , `customer` a `supplier` . Diakritika sa riesi cez `unaccent` a konfiguraciu `sk` . Novsie zmluvy su mierne boostnute vo vyslednom ranku.

Pre `supplier_ico` a `identifier` je vhodnejši trigram index, pretoze zadanie vyzaduje hladanie podretazca hocikde vo vnútri hodnoty.