

Lab 9 - Elasticsearch

Skripty su v 9/src/ , query su v 9/queries/ , vystupy su v 9/outputs/ .

Dataset

Použil som Palmer Penguins dataset.

Zdroj:

<https://raw.githubusercontent.com/mwaskom/seaborn-data/master/penguins.csv>

Dataset obsahuje merania tucniakov z Palmer Archipelago. Polia su napríklad:

- species
- island
- bill_length_mm
- bill_depth_mm
- flipper_length_mm
- body_mass_g
- sex
- year

Import

Elasticsearch kontajner:

```
docker run -d --name db2-lab9-es -p 9200:9200 -p 9300:9300 -e "discovery.type=single-node" elasti
```

Import cez Python:

```
python src/import_penguins.py
```

Import vytvori index `penguins` , mapping a nahra dokumenty cez `_bulk` API.

Overeny import:

Index	Pocet dokumentov
penguins	344

Query 1 - textove hladanie

Subor:

```
queries/01_search_text.json
```

Dotaz hlada text:

```
Gentoo Biscoe
```

Pouziva `multi_match` nad polami:

- `species`
- `island`
- `description`

Vystup je v `outputs/01_search_text.txt`.

Vysledok:

Hodnota	Vysledok
pocet najdenych dokumentov	168
prvy druh vo vysledkoch	Gentoo
prvy ostrov vo vysledkoch	Biscoe

Query 2 - agregacia

Subor:

```
queries/02_aggregation_species_body_mass.json
```

Agregacia zoskupi dokumenty podla druhu tucniaka a spocita:

- priemernu hmotnost
- priemernu dlzku plutvy

Vystup je v `outputs/02_aggregation_species_body_mass.txt` .

Species	Pocet	Priemerna hmotnost	Priemerna dlzka plutvy
Adelie	152	3700.66 g	189.95 mm
Gentoo	124	5076.02 g	217.19 mm
Chinstrap	68	3733.09 g	195.82 mm

Query 3 - doplnkova agregacia

Subor:

```
queries/03_aggregation_islands.json
```

Agregacia spocita, kolko zaznamov je z kazdeho ostrova.

Vystup je v `outputs/03_aggregation_islands.txt` .

Island	Pocet
Biscoe	168
Dream	124
Torgersen	52

Zaver

Elasticsearch index `penguins` umoznuje textovo hladat v poliach ako `species` a `island` . Agregacie sa robia nad `keyword` alebo numerickymi poliami. V tomto labe je textove hladanie ukazane cez `multi_match` a agregacia cez `terms + avg` .